

水豚噜噜学AI之什么是RAG



Data26.09.17

Ryan

RAG(Retrieval Augmented Generation)

检索

增强

生成

一、RAG的本质

1. 一套成型的知识工程方案。遇到问题到知识库找资料

Retrieval

2. 用找到的资料加问题用模板组成提示词

Augmented

3. 要求大模型阅读资料、并按照Prompt进行回答

Generation

大模型无正确答案这概念。不说不知道,而是非常不拐弯子构造一个概率上最合适的答案

二、为什么需要RAG

LLM大模型: 基于输入数据训练的语言概率分布函数

知识边界受限, 则无法包含企业私域信息等非公开信息


三、RAG的具体落地

阶段一 知识库搭建

Load读取



项目说明书
工艺手册
各种PDF word

提取



把各种知识按不同的格式统一为纯文本

chunking分块



无数的切片

可按文字数量

标点
章杰

进行切

问: 为什么进行切片, 不把整个文本给大模型

答：上下文窗口有限，顶级模型的上下文窗约200万Token约150万字，所以企业知识大多放不下，就算放下了，当输入量超过窗口的50%，模型的注意力会严重衰减，关键信息的召回准确率会从90%暴跌到30%以下，而且每个Query都把整个文本给到模型，时间成本和Token成本会爆炸。

embedding 向量化

不是简单的二维、三维 千维!!!

把无数的切片变为向量坐标


这里我细说一下为什么要向量化

答：计算机用晶体管电路的高低电平，也就是二进制编码一切，所以计算机的一切都需要整数算术和逻辑判断，所以需要把词义表示为数字。

所以只要坐标的维度够多就可以表示一切


比如把苹果和香蕉以界门纲目科属种来多维对比

一维方式:



如果以一维的方式。计算机会把苹果和香蕉当作完全一个东西来看

二维方式:



所以当升维为二维后,苹果和香蕉,在坐标上有一定的距离
但是还有其他同目的植物,比如在二维坐标上生姜和香蕉的距离比苹果和香蕉的距离更近

和大语言模型本质是一样的
都是Transformer
只是LLM后接的生成层

结论:维度越高,语义关系越清晰。向量化的作用就是用embed

模型建立一个高维度的空间,比如3072维 然后跟据海量数

训练出的经验把文本按照他们的语义放在空间的合适位置

↓
存入向量数据库

这种数据库特点是在海量数据中做毫秒级快速查找

OK!阶段一结束

阶段二 答案生成

问题向量化

用户:苹果多少钱一个"



此时把用户问题用之前的embedding向量化模型得到向量

用相同的模型是为了向量化的语义逻辑

相同



检索

现在有了问题的向量编码, 用余弦相似度, 余弦相似度

越趋近于1, 表示向量夹角越小关系越密切

$$\cos = \frac{\vec{AB}}{|\vec{A}| |\vec{B}|}$$

数据库一般会把最密切的前几个拿出来, 取名为TOPK

套Prompt

在前面拿到的分块, 比如三个分块分别为分块一, 分块二, 分块三给到模板提示词

分块一: 苹果手机5999一个

分块二: 苹果5块钱一个

分块三: 青菜果比红苹果难吃

Prompt: "你是一个苹果客服, 现在请参考

分块一, 分块二, 分块三

给出你的答案"

给大模型LLM出答案

全部结束!!!

所以全部步骤只有最后一步用大模型, 很省Token